

Matriz de Confusao - CNN

Valor Real

Predito

1 2 3 4 5 6 7 8 9 10 11 12

janeiro

fevereiro

marco

abril

maio

junho

julho

agosto

setembro

outubro

novembro

dezembro

35

30

25

20

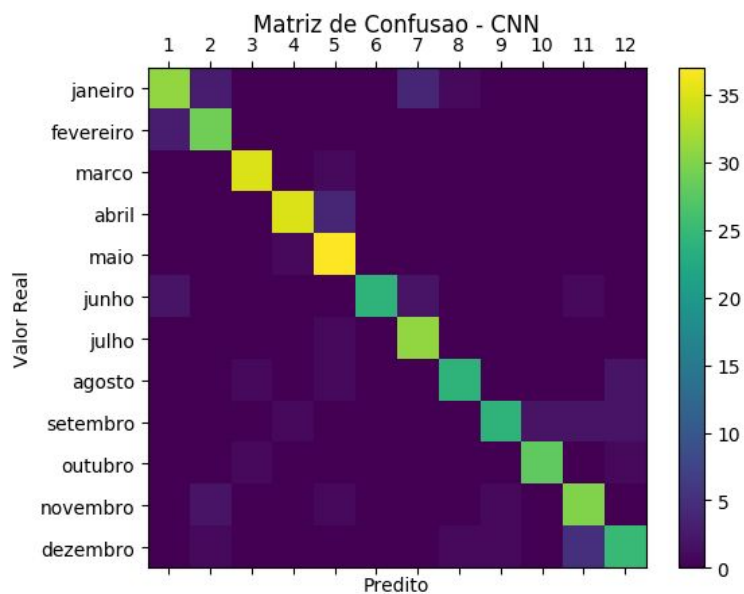
15

10


5

0

Test loss: 56.92%, Test accuracy: 84.79%




Test loss: 71.55%, Test accuracy: 83.04%




Executando o código com as configurações iniciais, ou seja, com GaussianNB:

Taxa de Reconhecimento: 56.36%




Utilizando o algoritmo Logistic Regression:

Taxa de Reconhecimento: 72.32%



Utilizando o método Random Forest:

Taxa de Reconhecimento: 60.6%

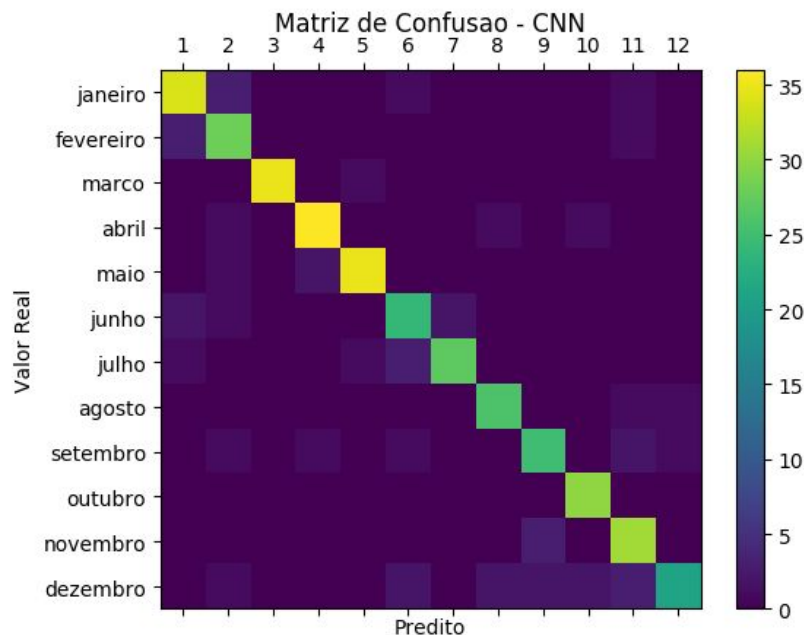


Podemos notar que o Logistic Regression apresentou o melhor resultado. Porém, nenhuma chegou próximo da melhor versão do CNN.

## 2.3 Data Augmentation

Aplicou-se uma técnica de data augmentation para gerar 3 novas imagens a partir de uma, variando o brilho da mesma. Chegou-se aos seguintes resultados com um tamanho de base de treinamento aumentado para 6312:

Test loss: 61.42%, Test accuracy: 87.78%



Não se pôde notar uma melhora significativa nos resultados, porém o tempo aumentou consideravelmente (de ~10min para ~3h30min). Talvez aplicando uma técnica diferente pudesse ter gerado um melhor desempenho.

## 3. Conclusão

A técnica de classificação CNN é poderosa e altamente configurável, porém requer um alto poder de processamento. A extração de características por meio do transfer learning não foi bem sucedida. A técnica de data augmentation pode ajudar em casos de uma base de treinamento pequena, contudo o tempo de processamento aumenta bastante. A junção dessas diversas técnicas permite resultados com menos erros. A disponibilidade de tempo e experiência do aplicador também influenciam no momento de fazer escolhas adequadas para montar um bom classificador.

## 4. Bibliografia

<https://www.pyimagesearch.com/2018/12/31/keras-conv2d-and-convolutional-layers/>  
<https://keras.io/layers/pooling/>  
<https://machinelearningmastery.com/how-to-configure-image-data-augmentation-when-training-deep-learning-neural-networks/>